

제4장 머신러닝 첫걸음 — 규칙을 쓰지 않고 분류하기

[전반부] 이론 강의

학습 목표

- 사람이 규칙을 직접 쓰는 방식과 모델이 데이터에서 규칙을 찾는 방식이 어떻게 다른지 설명한다
- 분류와 회귀를 자기 주변의 예로 구분한다
- 훈련 데이터와 테스트 데이터를 왜 나누는지 설명한다
- 기준선 모델을 만들고, 새 모델을 기준선과 비교한다
- 정확도 하나만 보면 왜 속는지, 혼동행렬이 무엇을 더 보여주는지 설명한다

지난 3주 동안 데이터를 표로 만들고 그림으로 그렸다. 이번 장에서는 그 표를 컴퓨터에게 주고 판단 기준을 찾게 한다. 딥러닝도 머신러닝의 한 갈래다. 신경망으로 들어가기 전에 "모델이 데이터를 보고 기준을 찾는다"는 생각부터 손으로 확인한다.

1. 규칙을 직접 쓰면 어디서 막히는가

1-1. 사람이 규칙을 쓰는 방식

컴퓨터에게 일을 시키는 가장 오래된 방법은 사람이 조건문을 쓰는 것이다.

```
if score >= 60:
    result = "합격"
else:
    result = "불합격"
```


이 방식은 강력하다. 기준이 분명하고, 왜 그렇게 판정했는지 한 줄로 설명할 수 있고, 데이터가 한 건도 없어도 돌아간다.

문제는 기준을 말로 쓸 수 없을 때 생긴다. 고양이 사진과 강아지 사진을 가르는 규칙을 조건문으로 써 보면 금방 막힌다. 귀가 뾰족하면 고양이라고 쓰면 뾰족한 귀를 가진 강아지에서 틀린다. 수염을 세면 사진마다 수염이 다르게 찍힌다. 조건을 하나 더할 때마다 예외가 두 개씩 늘어난다.

1-2. 모델이 규칙을 찾는 방식


머신러닝은 순서를 바꾼다. 사람은 규칙 대신 **예시**를 준다. 예시에는 입력과 정답이 함께 들어 있다. 모델은 그 둘의 관계를 보고 판단 기준을 스스로 만든다.

규칙 기반 방식 — 사람이 판단 기준을 직접 쓴다



규칙을 말로 쓸 수 없는 문제(고양이 사진 구분)에서는 막힌다

머신러닝 방식 — 모델이 데이터에서 판단 기준을 찾는다



규칙이 사라진 것이 아니다. 규칙을 쓰는 주체가 사람에서 모델로 바뀐 것이다

그림 4.1 두 방식의 차이 — 규칙이 사라진 것이 아니라, 규칙을 쓰는 주체가 사람에서 모델로 바뀐다

여기서 오해를 하나 정리한다. 머신러닝은 규칙 없이 판단하는 방법이 아니다. 모델도 결국 어떤 기준선을 긋는다. 다만 그 선을 사람이 문장으로 쓰지 않고, 데이터를 보며 찾을 뿐이다. 실습 4.1에서 모델이 찾은 선을 숫자로 뽑아 볼 텐데, 그 선은 사람이 손으로 그은 선과 같은 종류의 식이다.

표 4.1 두 방식 비교

구분	규칙 기반 방식	머신러닝 방식
사람이 하는 일	규칙을 직접 쓴다	예시 데이터를 모은다
컴퓨터가 하는 일	규칙을 적용한다	데이터에서 기준을 찾는다
잘 맞는 문제	점수 기준 합격 판정, 세금 계산	사진 분류, 댓글 분류, 추천
막히는 지점	기준을 말로 쓸 수 없을 때	데이터가 적거나 한쪽으로 치우쳤을 때
결과를 설명하는 방법	규칙을 그대로 읽는다	모델이 만든 기준을 꺼내 본다

○ 체크 질문

- 학교 장학금 선발을 규칙 기반으로 짜면 어디까지 되고, 어디서 막히는가
- 반대로 머신러닝으로 짜면 무엇이 위험한가

2. 분류와 회귀 — 답이 이름인가 숫자인가

머신러닝 문제는 정답의 생김새로 크게 둘로 나뉜다.

○ **분류(classification)** — 정답이 **이름**일 때

- 스팸인가 정상인가, 고양이인가 강아지인가, 통과인가 미통과인가
- 답의 종류가 정해져 있고, 그중 하나를 고른다

○ **회귀(regression)** — 정답이 **숫자**일 때

- 내일 기온은 몇 도인가, 이 중고차는 얼마인가, 이 학생의 점수는 몇 점인가
- 답이 연속된 값이고, 딱 떨어지는 후보가 없다

표 4.2 같은 데이터라도 무엇을 묻느냐에 따라 문제가 달라진다

가진 데이터	분류 문제로 물으면	회귀 문제로 물으면
학생의 공부 시간, 수면 시간	시험에 통과할까	시험 점수가 몇 점일까
메일의 링크 수, 대문자 비율	스팸일까	스팸일 확률이 몇 %일까
사진의 픽셀값	고양이일까 강아지일까	사진 속 동물의 나이가 몇 살일까

이번 장의 실습은 둘 다 분류다. 회귀는 6장에서 손실함수를 다룰 때 다시 나온다.

○ **자주 하는 실수**

- 별점 1~5를 예측하는 문제를 회귀로만 보면, 3.7점이라는 답이 나온다. 별점에 3.7은 없다
- 반대로 기온을 분류로 보면 20도와 21도를 완전히 다른 이름으로 취급해, 1도 차이와 30도 차이를 똑같이 틀린 것으로 센다
- 정답이 이름인지 숫자인지는 데이터가 아니라 **내가 무엇을 묻는지**가 정한다

3. 훈련 데이터와 테스트 데이터

모델을 만들 때 가진 데이터를 전부 쓰면 안 된다. 반드시 일부를 떼어 숨겨 둔다.

가진 데이터를 둘로 나눈다




그림 4.2 가진 데이터를 둘로 나눈다 — 모델은 훈련 데이터만 보고 배우고, 성적은 테스트 데이터에서 잰다

이유는 단순하다. 모델이 이미 본 데이터에서 성적을 재면, 답을 보고 시험을 치는 것과 같다. 시험 범위를 통째로 외운 학생과 원리를 이해한 학생은 연습 문제에서 똑같이 100점을 받는다. 둘을 가르려면 처음 보는 문제를 줘야 한다.

○ 나누는 방법

- 보통 훈련 7 : 테스트 3, 또는 8 : 2로 나눈다
- 나눌 때 두 그룹의 비율을 맞춘다(`stratify`). 통과 학생이 훈련 쪽에만 몰리면 비교가 성립하지 않는다
- 한 번 테스트로 떼어 낸 데이터는 모델을 고칠 때 **보지 않는다**

○ 지금은 넘어가는 것

- 실무에서는 훈련 · 검증 · 테스트 셋으로 나눈다. 검증 데이터는 모델을 고르는 데 쓰고, 테스트는 마지막에 딱 한 번 쓴다
- 이 구분은 7장(과적합)에서 다시 다룬다. 이번 장은 둘로만 나눈다

4. 기준선 — 비교 상대가 없으면 잘했는지 알 수 없다

"정확도 95%"라는 말만으로는 아무것도 알 수 없다. 95%가 좋은 성적인지 나쁜 성적인지는 **아무 생각 없이 찍었을 때 몇 %가 나오는지**와 비교해야 정해진다.

기준선(baseline)은 그 비교 상대다. 만드는 방법은 간단하다.

○ 가장 흔한 기준선 — 훈련 데이터에서 더 많았던 쪽으로만 답한다

- 통과 학생이 더 많으면, 테스트 데이터 전부를 통과로 찍는다
- 데이터를 보지도 않고, 학습도 하지 않는다

○ 기준선을 만드는 이유

- 새 모델이 기준선을 못 넘으면, 그 모델은 데이터에서 아무것도 배우지 못한 것이다
- 반대로 기준선이 이미 95%라면, 96%짜리 모델은 자랑거리가 아니다

실습 4.1에서 기준선 정확도는 0.500이 나왔다. 두 그룹의 수가 거의 같았기 때문이다. 실습 4.2에서는 같은 기준선이 0.950까지 올라간다. 왜 그런지는 다음 절에서 다룬다.

5. 정확도 하나만 보면 속는다

정확도(accuracy)는 맞힌 비율이다.

정확도 = 맞힌 개수 / 전체 개수

계산이 쉽고 한 숫자로 요약되니 편하다. 그래서 위험하다.

○ 한쪽이 드물면 정확도가 무너진다

- 메일 1000통 중 스팸이 50통이라고 하자. 스팸은 전체의 5%다
- "전부 정상"이라고만 답하는 프로그램을 만들면 950통을 맞힌다. 정확도 95%다
- 이 프로그램은 스팸을 **한 통도** 못 잡는다. 그런데 성적표에는 95%라고 찍힌다

이런 데이터를 **불균형 데이터**라고 부른다. 실제로 중요한 문제는 대부분 불균형하다. 불량품, 질병, 사기 거래, 재난 신고는 전부 드물게 일어난다. 드물기 때문에 찾아낼 값어치가 있고, 드물기 때문에 정확도가 속인다.

Google 머신러닝 단기집중과정도 같은 예를 든다. 한 클래스가 1%만 나타나는 데이터에서는 전부 음성이라고 답하는 모델이 정확도 99%를 기록하지만, 그 모델은 쓸모가 없다.¹

○ 그래서 무엇을 봐야 하는가

- 기준선 정확도를 먼저 계산한다. 내 모델이 그보다 나은가
- 맞힌 비율이 아니라 **무엇을 놓쳤는지** 센다. 그 도구가 다음 절의 혼동행렬이다

6. 혼동행렬 — 어느 방향으로 틀렸는가

혼동행렬(confusion matrix)은 예측과 정답을 짝지어 개수를 센 표다. 답이 두 종류면 칸이 네 개 생기고, 그중 두 칸이 틀린 예측을 담는다. 틀리는 방향이 하나가 아니라는 것이 핵심이다.

○ 놓쳤다 — 정답은 스팸인데 정상이라고 했다

- 스팸이 받은편지함에 들어온다. 사용자가 광고를 본다

○ 헛짚었다 — 정답은 정상인데 스팸이라고 했다

- 합격 통보 메일이 스팸함으로 간다. 사용자가 중요한 메일을 놓친다

두 오류의 무게는 문제마다 다르다. 스팸 필터에서는 헛짚는 쪽이 더 아프고, 질병 검사에서는 놓치는 쪽이 훨씬 위험하다. 정확도는 이 둘을 그냥 더해 버려서 구분하지 못한다. 혼동행렬은 나눠서 보여준다.

네 칸의 이름

찾으려는 쪽(여기서는 스팸)을 **양성(positive)**, 나머지(정상)를 ****음성(negative)****이라고 부른다. 칸 이름의 뒤 낱말은 모델이 예측한 쪽이고, 앞 낱말(참/거짓)은 그 예측이 맞았는지도.

표 4.3 혼동행렬 네 칸의 이름 (양성 = 스팸)

	예측: 스팸(양성)	예측: 정상(음성)
실제: 스팸	참양성 TP — 잡았다	거짓음성 FN — 놓쳤다
실제: 정상	거짓양성 FP — 헛짚었다	참음성 TN — 맞게 넘겼다

위의 두 오류를 이 이름으로 다시 부르면, "놓쳤다"가 거짓음성(FN)이고 "헛짚었다"가 거짓양성(FP)이다.

네 칸으로 계산하는 세 지표

숫자를 넣어 계산한다. 메일 100통 중 실제 스팸이 20통이고, 모델이 10통을 스팸이라고 불렀는데 그중 9통이 진짜 스팸이었다고 하자.

표 4.4 계산 예시 — 메일 100통, 실제 스팸 20통

	예측: 스팸	예측: 정상	합계
실제: 스팸	TP = 9	FN = 11	20
실제: 정상	FP = 1	TN = 79	80
합계	10	90	100

○ 정확도(accuracy) — 전체 중에 맞힌 비율

- 정확도 = $(TP + TN) / \text{전체} = (9 + 79) / 100 = 88\%$
- 5절에서 봤듯이, 불균형 데이터에서는 이 숫자만 보면 속는다

○ 정밀도(precision) — 스팸이라고 부른 것 중 진짜 스팸의 비율

- 정밀도 = $TP / (TP + FP) = 9 / (9 + 1) = 90\%$
- 분모가 **모델이 양성이라 부른 개수**다. 표의 세로줄(예측: 스팸)을 본다
- 정밀도가 낮으면 헛짚음(FP)이 많다는 뜻이다. 중요한 업무 메일이 스팸함으로 들어간다

○ 재현율(recall) — 실제 스팸 중 모델이 잡아낸 비율

- 재현율 = $TP / (TP + FN) = 9 / (9 + 11) = 45\%$
- 분모가 **실제 양성의 개수**다. 표의 가로줄(실제: 스팸)을 본다

- 재현율이 낮으면 놓침(FN)이 많다는 뜻이다. 의학에서는 민감도(sensitivity)라고도 부른다
- 예: 실제 감염자 10명을 검사해 8명만 양성이 나왔다면 재현율은 $8 / 10 = 80\%$ 다. 나머지 2명은 감염된 채 정상 판정을 받았다

같은 표에서 나온 세 숫자가 전부 다르다 — 정확도 88%, 정밀도 90%, 재현율 45%. 이 모델은 스팸이라 부른 것은 거의 맞지만, 실제 스팸의 절반 이상을 놓친다. 정확도 한 숫자에는 이 차이가 담기지 않는다.

표 4.5 세 지표 비교

지표	물어 보는 것	분모	낮을 때 생기는 일
정확도	전체 중 몇 개를 맞혔는가	전체 데이터 수	불균형 데이터에서는 높아도 의미가 없을 수 있다
정밀도	양성이라 부른 것 중 진짜는 몇인가	TP + FP (예측 양성)	정상 메일이 스팸함으로 간다 (헛짚음)
재현율	실제 양성 중 몇 개를 잡았는가	TP + FN (실제 양성)	실제 환자가 정상 판정을 받는다 (놓침)

어느 지표를 우선하는가 — 문제가 정한다

두 지표 중 무엇을 우선할지는 두 오류(FN·FP) 중 어느 쪽 비용이 큰지로 정해진다. 네 칸의 구조는 어느 문제에서나 같지만 비용이 큰 칸은 문제마다 달라지므로, 두 사례를 숫자로 비교한다. 아래 두 표의 숫자는 실행 결과가 아니라 설명을 위해 가정한 값이다.

스팸 필터 — 헛짚음의 비용이 크다, 그래서 정밀도를 본다

메일 1000통(실제 스팸 50통, 정상 950통)에 필터 두 개를 돌렸다고 하자. 필터 A는 조금이라도 의심되면 차단하고, 필터 B는 확실할 때만 차단한다.

표 4.6 스팸 필터 두 후보의 혼동행렬 — 각 칸은 필터 A / 필터 B, 메일 1000통 중 실제 스팸 50통 (가정한 값)

	예측: 스팸(양성)	예측: 정상(음성)	합계
실제: 스팸	TP = 48 / 30	FN = 2 / 20	50
실제: 정상	FP = 30 / 3	TN = 920 / 947	950
합계	78 / 33	922 / 967	1000

○ 세 지표를 계산하면

- 정확도 — $A = (48 + 920) / 1000 = 96.8\%$, $B = (30 + 947) / 1000 = 97.7\%$. 차이가 0.9%p뿐이어서 정확도로는 둘을 가르기 어렵다
- 정밀도 — $A = 48 / 78 = 61.5\%$, $B = 30 / 33 = 90.9\%$

- 재현율 — $A = 48 / 50 = 96.0\%$, $B = 30 / 50 = 60.0\%$

○ 그래서 필터 B를 쓴다

- A는 정상 메일 30통을 스팸함에 넣는다. 그 안에 합격 통보나 거래처 회신이 있으면 사용자는 스팸함을 열어 보기 전까지 사라진 줄도 모른다
- B는 광고 메일 20통을 놓치지만, 사용자가 받은편지함에서 직접 지우면 그것으로 끝난다
- 정밀도 = $TP / (TP + FP)$ 이므로 FP를 30통에서 3통으로 줄이면 정밀도가 61.5%에서 90.9%로 오른다. 스팸 필터는 이 값을 먼저 본다

암 검진 — 놓침의 비용이 크다, 그래서 재현율을 본다

수검자 10,000명 중 실제 암 환자가 100명(1%)이라고 하자. 검사 A는 조금이라도 의심되면 양성으로 판정하고, 검사 B는 확실할 때만 양성으로 판정한다.

표 4.7 암 검진 두 후보의 혼동행렬 — 각 칸은 검사 A / 검사 B, 수검자 10,000명 중 실제 환자 100명 (가정한 값)

	예측: 암(양성)	예측: 정상(음성)	합계
실제: 암	TP = 95 / 60	FN = 5 / 40	100
실제: 정상	FP = 495 / 20	TN = 9,405 / 9,880	9,900
합계	590 / 80	9,410 / 9,920	10,000

○ 세 지표를 계산하면

- 정확도 — $A = (95 + 9,405) / 10,000 = 95.0\%$, $B = (60 + 9,880) / 10,000 = 99.4\%$
- 정밀도 — $A = 95 / 590 = 16.1\%$, $B = 60 / 80 = 75.0\%$
- 재현율 — $A = 95 / 100 = 95.0\%$, $B = 60 / 100 = 60.0\%$

○ 그래서 검사 A를 쓴다

- 정확도만 보면 B가 4.4%p 높다. 그런데 B는 암 환자 40명을 정상이라고 판정해 집으로 돌려보내고, 그 사이에 지나간 치료 시기는 되돌릴 수 없다
- A가 헛짚은 495명은 건강한데도 추가 정밀검사를 받는다. 비용과 불안이 생기지만 그 검사로 바로잡는다
- 재현율 = $TP / (TP + FN)$ 이므로 FN을 40명에서 5명으로 줄이면 재현율이 60.0%에서 95.0%로 오른다. 암 검진은 이 값을 먼저 본다
- 5절에서 본 정확도의 함정이 여기서 다시 나타난다. 정확도가 높은 쪽을 고르면 환자 35명을 더 놓친다

두 표의 네 칸 배치는 똑같고 굵게 표시한 칸만 반대쪽이다. 스팸 필터에서는 왼쪽 아래 거짓양성(FP)이, 암 검진에서는 오른쪽 위 거짓음성(FN)이 비용이 큰 오류다. 판단 기준은 두 경우 모두 같다 — **되돌릴 수 있는 오류와 되돌릴 수 없는 오류를 비교한다.** 이 비교는 데이터가 아니라 그 문제를 아는 사람이 한다.

두 지표는 함께 오르지 않는다

정밀도와 재현율은 한쪽을 올리면 다른 쪽이 내려가는 관계다. 모델이 양성이라고 부르는 기준을 조이면 정밀도가 오르는 대신 재현율이 떨어지고, 풀면 그 반대가 된다. 표 4.4의 모델로 두 극단을 계산해 보면:

○ 스팸을 하나도 안 놓치려고 100통 전부를 스팸이라 부르면 — 재현율 = $20/20 = 100\%$, 정밀도 = $20/100 = 20\%$

○ 반대로 가장 확실한 1통만 스팸이라 부르면 — 정밀도 = $1/1 = 100\%$, 재현율 = $1/20 = 5\%$

F1 점수 — 두 지표를 하나로 합칠 때

정밀도와 재현율을 한 숫자로 합쳐 모델을 비교해야 할 때는 F1 점수를 쓴다. 두 값의 조화평균이다.

$$F1 = 2 \times (\text{정밀도} \times \text{재현율}) / (\text{정밀도} + \text{재현율})$$

표 4.4의 모델로 계산하면 $F1 = 2 \times (0.90 \times 0.45) / (0.90 + 0.45) = 0.81 / 1.35 = \mathbf{0.60}$ 이다.

○ 산술평균이 아니라 조화평균을 쓰는 이유 — 조화평균은 둘 중 낮은 쪽으로 끌려간다

- 정밀도 90%와 재현율 45%의 산술평균은 67.5%지만, F1은 60%다
- 한쪽이 0이면 F1도 0이다. 5절의 "전부 정상" 프로그램은 재현율이 0이므로, 정확도가 95%여도 F1은 0점이다

○ 주의 — F1은 정밀도와 재현율을 같은 무게로 합친다. 스팸 필터나 암 검진처럼 한쪽이 확실히 더 중요한 문제라면, F1 한 숫자보다 두 지표를 나란히 놓고 보는 쪽이 낫다

○ 읽는 순서

1. 가로줄(실제 양성)을 본다. 실제 스팸 중 몇 통을 잡았는가 — 이것이 재현율이다
2. 세로줄(예측 양성)을 본다. 스팸이라고 부른 것 중 몇 통이 진짜였는가 — 이것이 정밀도다
3. 두 빨간 칸 중 이 문제에서 더 아픈 쪽을 정한다. 그쪽 지표를 우선한다

이 지표들을 실제 모델에서 계산하는 것은 실습 4.2에서 한다.

7. 직접 움직여 보는 웹 자료

수업에서 다 보여줄 수 없는 그림은 아래 자료로 보충한다. 모두 무료이고, 아래 설명은 각 페이지를 열어 확인한 내용이다.

자료	무엇을 볼 수 있는가	주소
MLU-Explain, Train/Test/Validation Sets	고양이·개 예시에서 훈련 데이터의 점을 마우스로 끌면 경계선이 따라 움직인다	https://mlu-explain.github.io/train-test-validation/
Google 머신러닝 단기집중과정 (한국어), 정확도·정밀도·재현율	혼동행렬의 네 칸으로 정확도를 정의하고, 불균형 데이터에서 정확도가 속이는 예를 든다	https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=ko

○ MLU-Explain의 드래그 실습은 실습 4.1과 짝이 된다. 점 하나를 옮겼을 뿐인데 선이 따라 움직이는 것을 보면, 모델이 데이터에서 기준을 찾는다는 말이 눈으로 이해된다

[후반부] 실습

두 가지를 한다. 첫 번째는 같은 데이터에 세 가지 방법을 붙여 성적을 겨루는 실습이고, 두 번째는 정확도 95% 모델의 정체를 밝히는 실습이다.

실행 환경

```
cd practice/chapter4
python -m pip install -r ../requirements.txt
```

필요한 패키지는 numpy, pandas, matplotlib, scikit-learn이다. GPU는 필요 없다. 두 실습 모두 노트북에서 몇 초 안에 끝난다.

실습 4.1: 같은 데이터, 다른 방법 — 세 가지 판단 기준을 겨룬다

실습 목표

- 점 하나가 무엇을 뜻하는지, 선 하나가 어떤 판단인지 눈으로 익힌다
- 같은 훈련 데이터를 방법 셋에 넘기고, 같은 테스트 데이터로 성적을 낸다
- 로지스틱 회귀가 찾은 선을 식으로, 결정 트리가 찾은 규칙을 조건문으로 꺼내 본다
- 방법을 바꿔도 훈련·테스트 절차는 그대로라는 것을 확인한다

데이터

점 하나가 학생 한 명이다. 가로축은 하루 공부 시간, 세로축은 하루 수면 시간이고, 색은 시험 통과 여부다. 공부와 수면이 모두 넉넉하면 통과할 확률이 높게 만들되, 잡음을 섞어 경계 근처에서는 결과가 갈리게 했다. 그래서 어떤 선을 그어도 틀리는 점이 남는다.

실행 명령

```
cd practice/chapter4/code
python 4-1-simple-classifier.py
```

핵심 코드

파일 맨 위에 학생이 바꿀 한 줄이 있다.

```
# 결정 트리가 조건문을 몇 단까지 겹쳐 쓸지 정한다. None 이면 제한이 없다.
MY_TREE_DEPTH = 3
```

로지스틱 회귀가 찾은 선을 사람이 읽을 수 있는 식으로 바꾸는 부분은 다음과 같다.

```
w0, w1 = model.coef_[0]      # 공부 시간에 붙는 무게, 수면 시간에 붙는 무게
b = model.intercept_[0]
slope = -w0 / w1             # 기울기
intercept = -b / w1          # y절편
```

결정 트리는 선 대신 조건문을 찾는다. 찾은 조건문은 글로 그대로 꺼낼 수 있다.

```
tree = DecisionTreeClassifier(max_depth=MY_TREE_DEPTH, random_state=RANDOM_SEED)
tree.fit(x_train, y_train)
print(export_text(tree, feature_names=["공부시간", "수면시간"], decimals=1))
```

전체 코드는 [practice/chapter4/code/4-1-simple-classifier.py](#) 참고

실행 결과

아래는 기본값(`MY_TREE_DEPTH = 3`)으로 실행한 로그다.

데이터: 컴퓨터로 만든 합성 데이터(실제 학생 자료 아님)

전체 160명 = 훈련 112명 + 테스트 48명

전체에서 통과한 학생: 79명, 미통과: 81명

=== 로지스틱 회귀가 찾은 선 ===

식: 수면시간 = $-1.59 \times$ 공부시간 + 13.96

훈련 데이터 정확도: 0.893

테스트 데이터 정확도: 0.938

=== 결정 트리가 찾은 규칙 (깊이 3) ===

훈련 데이터 정확도: 0.938

테스트 데이터 정확도: 0.938

출처: `practice/chapter4/results/4-1-simple-classifier.log`

로그는 이 규칙을 들여쓴 조건문으로 찍는다. 같은 규칙을 가지가 갈라지는 그림으로 옮기면 어느 조건이 어느 조건 아래에 붙는지가 위치로 드러난다.

결정 트리가 찾은 판단 기준 — 조건이 맞으면 왼쪽, 아니면 오른쪽으로 내려간다




그림 4.3 결정 트리가 찾은 규칙 — 회색 상자가 모델이 고른 조건, 색 상자가 최종 판정이다. 상자의 **훈련 n명**은 그 자리에 내려온 훈련 데이터 수다

표 4.8 테스트 데이터 48명에서 세 방법 비교

방법	테스트 정확도
기준선(무조건 한쪽으로 찍기)	0.500
로지스틱 회귀가 찾은 선	0.938
결정 트리가 찾은 규칙	0.938

두 모델이 찾은 판단 기준 — 로지스틱 회귀 · 결정 트리 (합성 데이터)




그림 4.4 초록 실선이 로지스틱 회귀가 찾은 선, 보라색 점선이 결정 트리가 나눈 경계다. X 표시는 테스트 데이터다

결과 읽기

○ **기준선 0.500** — 통과 79명과 미통과 81명이 거의 반반이라, 한쪽으로만 찍으면 절반만 맞는다. 여기가 출발선이다

○ **로지스틱 회귀 0.938** — 기준선을 44%p 앞섰다. 모델이 마법을 부린 것이 아니라, 훈련 데이터 112명을 하나씩 대조하며 선의 기울기와 위치를 조정했을 뿐이다. 그 조정을 어떤 규칙으로 하는지는 6장에서 다룬다

○ **결정 트리 0.938** — 성적은 같은데 판단 기준의 모양이 다르다

- 로지스틱 회귀는 직선 하나를 내놓았고, 결정 트리는 조건문 일곱 줄을 내놓았다. 테스트 정확도는 둘 다 0.938이다
- 트리가 쓴 첫 조건은 공부시간 ≤ 6.1 이다. 1절에서 사람이 손으로 쓰던 `if 시험점수  $\geq 60$` 과 같은 모양인데, 기준값 6.1을 사람이 아니라 모델이 훈련 데이터 112명에서 골랐다
- 그림 4.4의 보라색 점선을 보면 경계가 계단 모양이다. 조건문이 한 번에 한 축만 자르기 때문에 비스듬한 선을 그을 수 없다

○ **훈련 성적과 테스트 성적은 같지 않다** — 로지스틱 회귀는 훈련 0.893, 테스트 0.938로 테스트 쪽이 오히려 높다. 결정 트리는 둘 다 0.938로 같다. 두 성적이 어긋나는 것을 어떻게 읽어야 하는지는 7장 (과적합)에서 다룬다. 지금은 "두 성적은 다를 수 있다"만 확인한다

○ **트리 깊이를 풀면 훈련 성적만 오른다** — `MY_TREE_DEPTH` 를 바꿔 가며 켜 결과다

깊이	훈련 정확도	테스트 정확도
1	0.866	0.854
2	0.866	0.854
3	0.938	0.938
제한 없음	1.000	0.917

출처: `practice/chapter4/results/4-1-simple-classifier.log`

- 제한을 풀면 훈련 112명을 **한 명도 틀리지 않는다**(1.000). 조건문을 계속 쪼개 학생 한 명씩 따로 처리한 것이다
- 그런데 테스트 정확도는 0.938에서 0.917로 내려갔다. 훈련 데이터를 외운 만큼 처음 보는 학생에게는 오히려 못 맞힌다
- 3절에서 데이터를 둘로 나눈 이유가 여기서 드러난다. 훈련 성적만 봤다면 제한 없는 트리를 가장 좋은 모델로 골랐을 것이다. 이 현상의 이름과 대처법은 7장에서 다룬다

해 보기

`MY_TREE_DEPTH` 를 1, 2, None 으로 바꿔 다시 실행하고 아래 세 질문에 답한다.

1. 깊이를 1로 두면 출력되는 조건문이 몇 줄인가. 깊이 3일 때와 몇 줄 차이인가
2. None 으로 두면 훈련 정확도와 테스트 정확도가 각각 얼마가 되는가
3. 조건문이 길어질수록 두 정확도는 각각 어느 쪽으로 움직이는가

○ 확인할 것은 **조건문을 잘게 쪼갤수록 두 성적이 어떻게 갈라지는지**다

○ 로지스틱 회귀가 -1.59 와 13.96 을 어떻게 골랐는지는 이 실습에서 다루지 않는다. 그 값을 찾아가는 규칙이 6장의 경사하강법이다

모델이 틀린 사례

순위	공부시간	수면시간	실제	모델예측
1	4.71	5.93	통과	미통과
2	4.06	7.78	미통과	통과
3	5.69	3.74	통과	미통과

출처: `practice/chapter4/results/misclassified_examples.csv`

세 명 모두 그림에서 선 가까이에 있다. 모델이 엉뚱한 곳에서 틀린 것이 아니라, 두 그룹이 섞이는 구간에서 틀렸다. 결정 트리도 방법을 바꿔도 테스트 정확도가 0.938로 같았다는 점이 같은 이야기를 한다. 판단 기준의 모양을 바꾸는 것으로는 섞인 구간의 오류가 없어지지 않는다.

실습 4.2: 정확도 95% 모델의 정체

실습 목표

- 불균형 데이터에서 정확도가 어떻게 사람을 속이는지 직접 본다
- 정확도가 가장 높은 모델이 가장 쓸모없을 수 있다는 것을 혼동행렬로 확인한다

데이터

메일 1000통을 만든다. 그중 스팸은 50통, 전체의 5%다. 특징은 두 개다.

- 메일에 들어 있는 링크 개수
- 제목에서 대문자가 차지하는 비율

스팸은 링크가 많고 대문자 비율이 높은 편이지만, 정상 메일과 겹치는 구간을 남겨 뒀다.

세 모델

모델	하는 일
A 무조건 정상	학습하지 않는다. 모든 메일을 정상이라고 답한다
B 기본 모델	로지스틱 회귀를 기본 설정으로 학습한다
C 스팸 중시 모델	같은 로지스틱 회귀에 "스팸을 놓치면 더 큰 손해"라고 알려주고 학습한다 (<code>class_weight="balanced"</code>)

실행 명령

```
cd practice/chapter4/code
python 4-2-accuracy-trap.py
```

실행 결과

전체 1000통 중 스팸 50통 = 5.0%

훈련 700통, 테스트 300통(테스트 안의 스팸 15통)

모델	정확도	정밀도	재현율	F1	스팸 잡음	정상을 스팸이라 함
A 무조건 정상	0.950	- 0.000	0.000	0/15	0	
B 기본 모델	0.967	1.000	0.333	0.500	5/15	0
C 스팸 중시 모델	0.883	0.250	0.667	0.364	10/15	30

출처: `practice/chapter4/results/4-2-accuracy-trap.log`

같은 세 모델을 혼동행렬로 펼치면 정확도 한 숫자에 가려진 차이가 드러난다. 세 표 모두 테스트 300통, 그중 실제 스팸 15통이고, 칸 배치는 표 4.6-4.7과 같다.

표 4.9 A 무조건 정상 — 정확도 0.950

	예측: 스팸(양성)	예측: 정상(음성)	합계
실제: 스팸	TP = 0	FN = 15	15
실제: 정상	FP = 0	TN = 285	285
합계	0	300	300

○ 예측: 스팸 열이 위아래 모두 0이다. 스팸이라고 부른 메일이 한 통도 없어 정밀도의 분모가 0이 된다

표 4.10 B 기본 모델 — 정확도 0.967

	예측: 스팸(양성)	예측: 정상(음성)	합계
실제: 스팸	TP = 5	FN = 10	15
실제: 정상	FP = 0	TN = 285	285
합계	5	295	300

○ FP가 0이라 정밀도는 $5/5 = 1.000$ 이다. 대신 FN이 10이라 재현율은 $5/15 = 0.333$ 에 그친다

표 4.11 C 스팸 중시 모델 — 정확도 0.883

	예측: 스팸(양성)	예측: 정상(음성)	합계
실제: 스팸	TP = 10	FN = 5	15
실제: 정상	FP = 30	TN = 255	285
합계	40	260	300

○ FN을 10에서 5로 줄인 대가로 FP가 0에서 30으로 늘었다. 6절에서 말한 맞교환이 칸의 수로 나타난다

출처: [practice/chapter4/results/4-2-accuracy-trap.log](https://practice.chapter4.results/4-2-accuracy-trap.log)

결과 읽기

이 표에서 확인할 것은 세 가지다.

○ A는 아무것도 하지 않고 95%를 받았다

- 학습을 한 줄도 하지 않았는데 정확도가 0.950이다. 스팸이 5%뿐이라 그렇다
- 표 4.9의 예측: 스팸 열이 위아래 모두 0이다. 스팸이라고 부른 메일이 한 통도 없다
- 정확도만 적힌 보고서였다면 이 모델이 통과했을 수도 있다

○ 정확도가 가장 높은 B가 스팸의 3분의 2를 놓쳤다

- B의 정확도 0.967은 셋 중 가장 높다
- 그런데 스팸 15통 중 5통만 잡았다. 10통은 그냥 통과시켰다
- 정확도 순위와 쓸모 순위가 어긋난다

○ 정확도가 가장 낮은 C가 스팸을 두 배 잡았다

- C의 정확도 0.883은 셋 중 가장 낮다. A보다도 낮다
- 그런데 스팸을 10통 잡았다. B의 두 배다
- 대신 정상 메일 30통을 스팸이라고 헛짚었다

○ 6절의 지표로 다시 읽으면

- A: 재현율 = $0/15 = 0\%$. 스팸이라 부른 메일이 없어 정밀도는 계산할 수 없다(분모가 0). 그래도 F1은 0.000으로 정해진다. 잡은 스팸이 0통이면 F1의 분자가 0이 되어 정밀도 값과 무관해지기 때문이다
- B: 정밀도 = $5/5 = 100\%$, 재현율 = $5/15 = 33\%$, F1 = 0.500. 부른 것은 전부 맞췄지만 셋 중 둘을 놓쳤다
- C: 정밀도 = $10/(10+30) = 25\%$, 재현율 = $10/15 = 67\%$, F1 = 0.364. 두 배로 잡는 대신 헛짚음이 늘었다
- B와 C가 정밀도·재현율의 반대 방향에 서 있다. 6절에서 말한 두 지표의 맞교환이 실제 모델에서 그대로 나타난다
- F1로 줄을 세우면 $B\ 0.500 > C\ 0.364 > A\ 0.000$ 이다. 정확도 순위($B\ 0.967 > A\ 0.950 > C\ 0.883$)와 달리 아무것도 하지 않은 A가 꼴찌로 내려간다

- 다만 F1은 정밀도와 재현율을 같은 무게로 합친 값이다. 6절에서 적었듯 스팸 필터처럼 한쪽이 더 중요한 문제에서는 F1 한 숫자로 결정하지 않고 두 지표를 나란히 본다

○ 그래서 어느 모델이 좋은가

- 이 질문에는 데이터만 보고 답할 수 없다. 무엇이 더 아픈지를 사람이 정해야 한다
- 광고 메일이 몇 통 들어오는 정도가 참을 만하다면 B를 고른다
- 스팸을 놓치는 쪽이 위험한 상황(피싱 메일 차단)이라면, 정상 메일 30통을 스팸함에서 다시 꺼내는 수고를 감수하고 C를 고른다
- 어느 쪽을 고르든, 정확도 한 숫자만 보고서에 적으면 이 판단 과정이 통째로 사라진다

해 보기

코드 위쪽의 값을 바꿔 다시 실행하고 아래 세 질문에 답한다.

```
N_MAILS = 1000
N_SPAM = 50
```

1. N_SPAM 을 10으로 줄이면(1%) 모델 A의 정확도는 몇으로 오르는가
2. N_SPAM 을 500으로 올려 반반으로 만들면 세 모델의 차이가 어떻게 되는가
3. 스팸 비율과 모델 A의 정확도 사이에 어떤 관계가 있는가

과제 (LMS 제출)

두 실습의 해 보기 질문 여섯 개에 답해 LMS에 올린다. 보고서 형식을 갖추지 않아도 된다.

제출물

질문 번호를 적고 그 아래에 답을 쓴 글 하나. 질문당 두세 줄이면 된다.

출처	질문	무엇을 바꿔 실행하는가
실습 4.1 해 보기	1~3	MY_TREE_DEPTH 를 1, 2, None 으로
실습 4.2 해 보기	1~3	N_SPAM 을 10, 500 으로

평가 기준

- 여섯 질문에 모두 답하면 완료로 인정한다. 답이 맞았는지는 채점하지 않는다
- 각 답에는 자기가 실행해서 얻은 수치가 하나 이상 들어 있어야 한다. 실행하지 않고 짐작으로 쓴 답은 인정하지 않는다

마감

- 실습 수업일 포함 7일 이내

핵심 정리

개념	한 줄 정리
규칙 기반 vs 머신러닝	규칙이 사라지는 것이 아니라, 규칙을 쓰는 주체가 사람에서 모델로 바뀐다
분류와 회귀	정답이 이름이면 분류, 숫자면 회귀다. 데이터가 아니라 질문이 정한다
훈련/테스트 분할	모델이 본 데이터에서 진짜 성적은 성적이 아니다
기준선	아무 생각 없이 찍었을 때의 점수. 이걸 못 넘으면 모델은 아무것도 배우지 못한 것이다
정확도	맞힌 비율. 한쪽이 드문 데이터에서는 사람을 속인다
혼동행렬	놓친 것과 헛짚은 것을 나눠서 보여준다. 둘의 무게는 문제마다 다르다

다음 장에서는 선 하나로 나눌 수 없는 데이터를 만난다. 그때 은닉층이 왜 필요한지가 드러난다.

1. Google, "정확성, 재현율, 정밀도 및 관련 측정항목", 머신러닝 단기집중과정. <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=ko> (2026년 8월 24일 확인)↩